

Generative Adversarial Networks

**Crearea de Carti TCG cu Deep
Learning**

Analiza implementarii si evolutiei modelului GAN

Iorga Mihai Liviu

Cum Functioneaza un GAN?

Generator

Transforma zgomot aleator in imagini

Invata sa creeze imagini care par reale

Scopul: Inselarea discriminatorului

Discriminator

Distinge intre imagini reale si false

Invata pattern-uri din date reale

Scopul: Detectarea imaginilor false

Procesul de Antrenare

1. Generatorul creeaza imagini false din zgomot aleator
2. Discriminatorul evalueaza imaginile produse de generator
3. Ambele retele invata simultan prin adversitate
4. Generatorul imbunatatestea calitatea imaginilor generate
5. Discriminatorul imbunatatesteste parametrii pentru detectie

Arhitectura Modelului

Generator

Input: Zgomot aleator (64 dimensiuni)

Layers: 5 straturi ConvTranspose2d

Activari: ReLU + BatchNorm

Output: Imagine 128x128x3

Discriminator

Input: Imagine 128x128x3

Layers: 3 straturi Conv2d

Activari: LeakyReLU + BatchNorm

Output: Scor binar (Real/Fake)

Transformari:

128x128 → 63x63 → 30x30 → 13x13 → Linear

Parametri de Antrenare

Learning Rate: 0.0001

Optimizer: Adam

Batch Size: 128

Epochs: 400

Loss Function

BCEWithLogitsLoss

Evolutia Antrenamentului: Epoch 1-100

Epoch 1

D_loss: 0.6878

G_loss: 0.6900

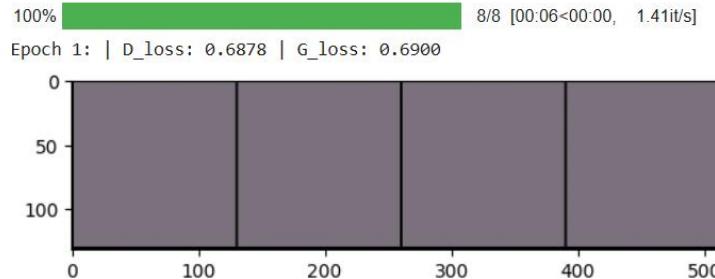
La inceput, ambele retele sunt slabe. Generatorul produce zgomot gri uniform.

Epoch 100

D_loss: 0.1680

G_loss: 2.0904

Discriminatorul devine puternic, generatorul incercă să creeze imagini credibile.



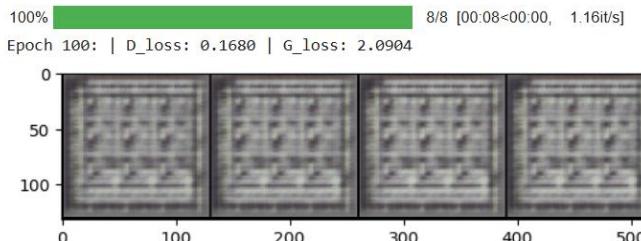
Observatii

Structura initială: Forme vagi de carti.

Culori: Pete de rosie, albastra si galbena.

Layout: Conturul chenarului se formează.

Detalii: Textura neclară și pixelată.



Evolutia Antrenamentului: Epoch 150-250

Epoch 150

D_loss: 0.6462 | **G_loss:** 1.0079

Echilibrul se restabileste. Generatorul se imbunatateste.

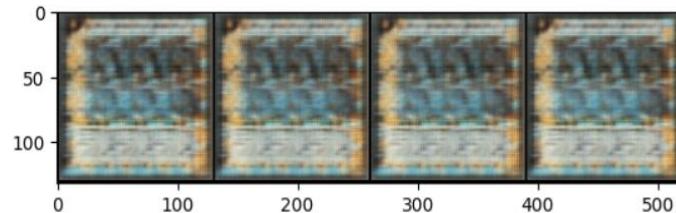
Epoch 200

D_loss: 0.6748 | **G_loss:** 0.9874

Echilibrul - fiecare se adapteaza la cealalta.

Faza de maturizare: Calitatea imaginilor creste semnificativ

Epoch 150: | D_loss: 0.6462 | G_loss: 1.0079



Im bunatati Vizibile

Contur definit: Chenarul clar vizibil.

Zona de text: Apar sectiuni cu text.

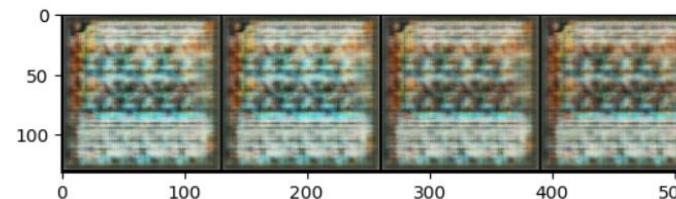
Illustratii: Forme sugestive.

Paleta: Culori diverse si realiste.

Textura: Suprafata omogena.

100% 8/8 [00:08<00:00, 1.15it/s]

Epoch 200: | D_loss: 0.4887 | G_loss: 1.2980



Evolutia Antrenamentului

300-400

Epoch 300

D_loss: 0.7551 | G_loss: 0.8129

Epoch 400 (Final)

D_loss: 0.6419 | G_loss: 1.0680

Faza finală: Model stabil cu output de calitate



Comparatie: Carte Reala vs. Carte Generata

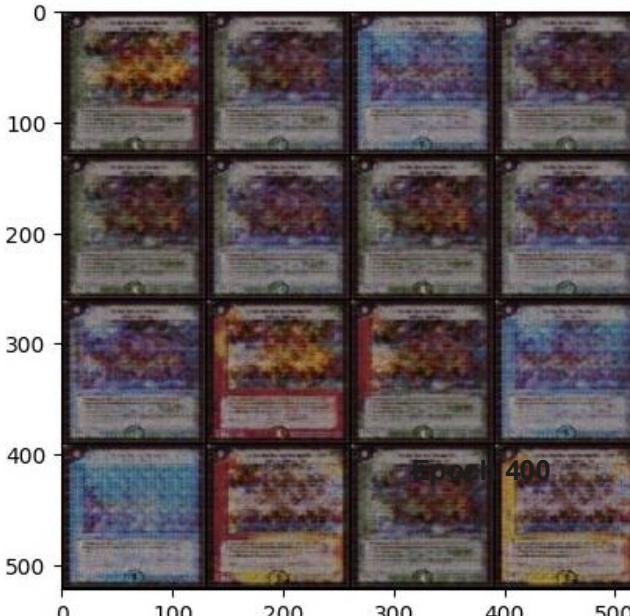
Carte
Originala



Bolshack Dragon

Carti
Generate

100% 8/8 [00:08<00:00, 1.09it/s]
Epoch 200: | D_loss: 0.6740 | G_loss: 0.9874



Concluzii si Perspective

Realizari

Model functional ce genereaza carti credibile
Convergenta stabila dupa 400 epoci
Diversitate in output

Limitari

Text neinteligibil
Detalii estompati
Rezolutie limitata (128x128)

Imbunatatiri Viitoare

Rezolutie: 256x256 sau 512x512 pixels
Arhitecturi: StyleGAN sau Progressive GAN
Conditional GAN: Control atribute
Dataset: Mai multe carti
Augmentation: Tehnici avansate